

Development of R&R Shoes E-commerce Platform with Machine Learning-Based Recommendation System

Mahendra Kirana M.B ¹, Henokh Abhinaya Tjahjadi ¹, Ammar Tyo Pasaribu ¹, Muhammad Aditya Permana ¹, Muh.Yusuf Fikry ¹, Andi Alisha Faiqihah ¹

¹ Universitas Hasanuddin; mbmk22h@student.unhas.ac.id, Tjahjadiha22h@student.unhas.ac.id, pasaribuat22h@student.unhas.ac.id, Permanama22h@student.unhas.ac.id, Fikrymy22h@student.unhas.ac.id, Faiqihahaa22h@student.unhas.ac.id
* Correspondence: pasaribuat22h@student.unhas.ac.id; Tel.: +62-895-6201-63633 (F.L.)

Abstrak: Website e-commerce sepatu R&R dikembangkan dengan mengintegrasikan sistem rekomendasi berbasis machine learning untuk meningkatkan pengalaman berbelanja pengguna. Penelitian ini menjelaskan pengembangan platform e-commerce yang menggunakan algoritma Non-negative Matrix Factorization (NMF) untuk menganalisis pola interaksi pengguna dan memberikan rekomendasi produk yang dipersonalisasi. Data dikumpulkan dari interaksi pengguna seperti view, wishlist, cart, dan pembelian, serta informasi produk dari berbagai kategori sepatu. Platform ini dibangun menggunakan React.js untuk frontend dan Flask untuk backend, dengan sistem rekomendasi yang dilatih untuk mengenali pola preferensi pengguna. Hasil evaluasi menunjukkan tingkat presisi dan recall yang baik dalam memberikan rekomendasi produk yang relevan. Dengan demikian, platform ini tidak hanya memudahkan pengguna dalam menemukan produk yang sesuai dengan preferensi mereka, tetapi juga membantu meningkatkan potensi konversi penjualan melalui rekomendasi yang dipersonalisasi.

Kata Kunci: Machine Learning; e-commerce; Sepatu

Abstract: The R&R shoes e-commerce website was developed by integrating a machine learning-based recommendation system to enhance the user shopping experience. This research describes the development of an e-commerce platform that utilizes the Non-negative Matrix Factorization (NMF) algorithm to analyze user interaction patterns and provide personalized product recommendations. Data is collected from user interactions such as views, wishlists, carts, and purchases, as well as product information from various shoe categories. The platform is built using React.js for frontend and Flask for backend, with a recommendation system trained to recognize user preference patterns. Evaluation results show good precision and recall rates in providing relevant product recommendations. Thus, this platform not only makes it easier for users to find products that match their preferences but also helps increase sales conversion potential through personalized recommendations.

Keywords: Machine Learning; e-commerce; Shoes

Citation: B, M.; Tjahjadi, H.; Pasaribu, A.; Permana, M.; Fikry, M.; Faiqihah, A. Development of RR Shoes E-commerce Platform with Machine Learning-Based Recommendation System. *Journal Not Specified*, , .

Received:
Accepted:
Published:

Copyright: © 2024 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

1. Project Charter

1.0.1. Project Description

Website e-commerce sepatu R&R merupakan platform penjualan sepatu online yang mengintegrasikan sistem rekomendasi berbasis machine learning. Proyek ini dirancang untuk meningkatkan pengalaman berbelanja pengguna dengan memberikan rekomendasi produk yang dipersonalisasi menggunakan algoritma Non-negative Matrix Factorization (NMF). Platform ini mengotomatisasi proses rekomendasi produk berdasarkan pola interaksi pengguna seperti view, wishlist, cart, dan pembelian. Dengan menerapkan teknologi modern seperti React.js untuk frontend dan Flask untuk backend, sistem ini tidak hanya menyediakan antarmuka yang responsif tetapi juga memproses data secara efisien untuk menghasilkan rekomendasi yang akurat.

1.0.2. Pembagian Role Tim

Nama	Role
Mahendra Kirana M.B	Project Manager
Henokh Abhinaya Tjahjadi	Backend Developer
Ammar Tyo Pasaribu	Backend Developer
Muh.Yusuf Fikry	Frontend Developer
Andi Alisha Faiqihah	Frontend Developer
Muhammad Aditya Permana	UI/UX Designer

Table 1. Pembagian Role Tim

1.0.3. SMART Question

Website e-commerce sepatu R&R dirancang untuk meningkatkan pengalaman berbelanja pengguna dengan mengintegrasikan sistem rekomendasi berbasis machine learning. Platform ini menggunakan teknologi Non-negative Matrix Factorization (NMF) untuk menganalisis pola interaksi pengguna dan memberikan rekomendasi produk yang dipersonalisasi. Dengan menggunakan data interaksi pengguna seperti view, wishlist, cart, dan pembelian, sistem dapat memahami preferensi pengguna dan memberikan rekomendasi yang relevan.

Inisiatif ini mendukung upaya peningkatan konversi penjualan melalui personalisasi pengalaman berbelanja, dengan memastikan bahwa setiap pengguna mendapatkan rekomendasi yang sesuai dengan preferensi mereka. Dengan menggunakan teknologi modern seperti React.js untuk frontend dan Flask untuk backend, platform ini diharapkan dapat memberikan layanan yang responsif dan efisien. Pada akhirnya, website ini ditargetkan untuk dapat dirilis dalam versi beta yang fungsional dalam waktu 16 minggu, menyediakan solusi e-commerce yang inovatif dengan fitur rekomendasi yang cerdas.

1.0.4. Alat / Tools

1. React.js
2. Flask
3. SQLite
4. Python (Scikit-learn)
5. Git
6. Figma

1.0.5. Target User

1. Pembeli sepatu online
2. Pengguna yang mencari rekomendasi sepatu
3. Pengguna yang sering berbelanja sepatu online

1.1. Situasi dan Kondisi Sekarang

Saat ini, banyak platform e-commerce sepatu yang beroperasi secara konvensional tanpa sistem rekomendasi yang efektif. Beberapa tantangan yang dihadapi:

- **Pengalaman berbelanja yang tidak personal:** Pengguna kesulitan menemukan produk yang sesuai dengan preferensi mereka
- **Keterbatasan dalam personalisasi:** Sistem rekomendasi yang ada masih belum optimal dalam memahami preferensi pengguna
- **Konversi penjualan yang belum maksimal:** Kurangnya rekomendasi yang tepat menyebabkan potensi penjualan tidak tercapai

1.2. *Proyek Sebelumnya yang Mirip*

Platform e-commerce dengan sistem rekomendasi telah banyak berkembang di Indonesia, dengan beberapa pemain besar seperti Tokopedia, Shopee, dan Bukalapak yang telah menerapkan sistem rekomendasi canggih dalam platform mereka. Di tingkat global, Amazon telah menjadi pionir dalam pengembangan sistem rekomendasi e-commerce dengan algoritma item-to-item collaborative filtering mereka yang terkenal.

Sistem rekomendasi yang diterapkan oleh platform-platform tersebut umumnya menggunakan kombinasi dari collaborative filtering dan content-based filtering untuk menganalisis pola belanja dan preferensi pengguna. Namun, sebagian besar platform ini menerapkan sistem rekomendasi untuk berbagai kategori produk secara umum, tidak terfokus pada kategori spesifik seperti sepatu.

R&R mengambil pendekatan yang berbeda dengan berfokus khusus pada kategori sepatu dan mengimplementasikan algoritma Non-negative Matrix Factorization (NMF) yang lebih sederhana namun efektif. Pendekatan ini memungkinkan personalisasi yang lebih spesifik untuk kategori produk tertentu, dengan mempertimbangkan karakteristik unik dari perilaku pembelian sepatu. Dengan fokus yang lebih spesifik ini, R&R dapat memberikan rekomendasi yang lebih relevan dan akurat untuk pengguna yang mencari produk sepatu.

2. **Methods**

2.1. *Data Collection*

Pengumpulan data dilakukan melalui penyusunan manual dan pencatatan interaksi pengguna untuk membangun dataset produk sepatu serta dataset interaksi pengguna. Langkah-langkah yang dilakukan adalah sebagai berikut:

Identifikasi Sumber Data:

- Dataset sepatu disusun dengan memasukkan produk dari lima kategori utama: formal, sport, heels, boots, dan casual.
- Setiap kategori terdiri dari 10 jenis sepatu berbeda, sehingga total terdapat 50 produk sepatu dalam dataset.

Pembuatan Dataset Produk:

- Dataset produk sepatu dibuat secara manual dengan menentukan nama sepatu, kategori, dan informasi dasar lainnya.
- Masing-masing sepatu diberi *id_sepatu* sebagai identitas unik untuk digunakan dalam pemetaan data interaksi.

Pengumpulan Data Interaksi Pengguna:

- Dataset interaksi pengguna (*user_interaction*) berisi data yang menunjukkan aktivitas pengguna pada setiap produk sepatu di situs.
- Data interaksi ini meliputi *id_user*, *id_sepatu*, dan jenis *interaction*, seperti *view*, *cart*, *buy*, dan *wishlist*, yang dicatat berdasarkan aktivitas pengguna.

Penyimpanan Data:

- Setiap data interaksi pengguna disimpan dalam format yang terstruktur di dalam dataset *user_interaction*.
- Data ini diatur agar mudah diakses oleh model rekomendasi untuk melatih sistem berdasarkan aktivitas pengguna yang relevan.

2.2. *Data Explanation*

Pada proyek ini, terdapat dua dataset utama yang digunakan untuk melatih model rekomendasi sepatu, yaitu Dataset Produk dan Dataset Interaksi Pengguna. Berikut adalah penjelasan lebih lanjut tentang kedua dataset ini:

2.2.1. Dataset Produk

Dataset produk mencakup informasi dasar mengenai sepatu yang tersedia di platform e-commerce. Setiap entri dalam dataset ini mewakili satu produk sepatu dan berisi atribut sebagai berikut:

- **id_sepatu**: ID unik untuk setiap sepatu. ID ini berfungsi sebagai pengidentifikasi yang akan dipetakan dalam dataset interaksi pengguna.
- **kategori**: Jenis atau kategori sepatu, seperti "formal", "sport", "heels", "boots", atau "casual". Kategori ini membantu mengelompokkan sepatu berdasarkan gaya dan fungsi.
- **nama_sepatu**: Nama atau model sepatu, yang dapat memberikan konteks bagi pengguna terkait produk yang ditawarkan.

Contoh entri dataset:

id_sepatu	kategori	nama_sepatu
1	formal	Wirken Oxford
2	sport	Ardiles Nfinity Burst
3	heels	Celline Heels
4	boots	Parabellum COBRA
5	casual	Asics Gel Sonoma SE

Dataset produk ini penting untuk memberikan konteks bagi sistem rekomendasi mengenai karakteristik dasar dari setiap produk.

2.2.2. Dataset Interaksi Pengguna (user_interaction)

Dataset ini berisi data interaksi antara pengguna dan produk di platform, yang mencakup berbagai aktivitas pengguna yang relevan. Atribut-atribut dalam dataset interaksi pengguna meliputi:

- **id_user**: ID unik pengguna yang melakukan interaksi. Atribut ini membantu dalam pelacakan aktivitas individual pengguna.
- **id_sepatu**: ID sepatu yang diinteraksikan oleh pengguna, menghubungkan dataset ini dengan dataset produk.
- **interaction_type**: Jenis interaksi yang dilakukan pengguna pada produk. Nilai ini dapat berupa:
 - view (melihat produk)
 - cart (memasukkan ke keranjang)
 - buy (membeli produk)
 - wishlist (menambahkan ke daftar keinginan)

Jenis interaksi ini digunakan untuk melatih model dalam memahami tingkat ketertarikan pengguna terhadap suatu produk.

Contoh entri dataset:

id_user	id_sepatu	interaction
1	12	view
1	2	buy
2	43	wishlist
3	24	cart
4	15	view

Dataset interaksi pengguna ini penting karena menjadi sumber utama dalam melatih model rekomendasi. Berdasarkan data ini, model dapat belajar pola preferensi pengguna untuk memberikan rekomendasi yang sesuai.

Dengan kedua dataset ini, model rekomendasi dapat dilatih untuk mengenali pola interaksi pengguna dan menawarkan produk yang relevan, meningkatkan pengalaman pengguna serta potensi konversi di platform e-commerce.

2.3. Theoretical Model

Model teoretis yang digunakan dalam proyek ini adalah *Non-negative Matrix Factorization* (NMF), yang merupakan teknik *Collaborative Filtering*. NMF dipilih karena kemampuannya dalam mengidentifikasi pola tersembunyi dalam data interaksi pengguna-produk dan menghasilkan rekomendasi yang dipersonalisasi. Berikut adalah penjelasan detail mengenai model teoretis yang digunakan:

1. Dasar Teori NMF:

- NMF adalah teknik dekomposisi matriks yang memfaktorkan matriks non-negatif V menjadi dua matriks non-negatif W dan H , di mana $V \approx WH$.
- Dalam konteks sistem rekomendasi:
 - V adalah matriks interaksi pengguna-produk
 - W adalah matriks yang merepresentasikan hubungan pengguna dengan fitur laten
 - H adalah matriks yang merepresentasikan hubungan fitur laten dengan produk
- Batasan non-negatif pada matriks memastikan interpretabilitas yang lebih baik dari fitur laten yang dihasilkan.

2. Formulasi Matematis:

- Objective Function:

$$\min_{W,H} \|V - WH\|_F^2 \text{ subject to } W, H \geq 0$$

- Di mana $\|\cdot\|_F$ adalah norma Frobenius
- Dimensi matriks:
 - $V \in \mathbb{R}^{m \times n}$
 - $W \in \mathbb{R}^{m \times k}$
 - $H \in \mathbb{R}^{k \times n}$
 - k adalah jumlah fitur laten yang dipilih

3. Keunggulan Model NMF:

- *Interpretabilitas*: Hasil faktorisasi dapat diinterpretasikan secara langsung karena semua nilai non-negatif.
- *Skalabilitas*: Dapat menangani dataset besar dengan efisien karena proses faktorisasi yang relatif sederhana.
- *Sparsitas*: Mampu menangani data yang sparse, yang umum dalam data interaksi pengguna-produk.
- *Fleksibilitas*: Dapat diintegrasikan dengan berbagai jenis data interaksi (view, wishlist, cart, buy).

4. Implementasi dalam Sistem Rekomendasi:

- *Representasi Data*:
 - Matriks interaksi dibentuk dengan pengguna sebagai baris dan produk sebagai kolom
 - Nilai dalam matriks merepresentasikan tingkat interaksi (1-4 untuk view, wishlist, cart, buy)
- *Proses Pembelajaran*:
 - Inisialisasi random untuk matriks W dan H
 - Iterative update rules untuk meminimalkan error rekonstruksi

–	Konvergensi dicapai ketika perubahan error minimal	199
•	<i>Pemberian Rekomendasi:</i>	200
–	Prediksi preferensi dihitung melalui perkalian WH	201
–	Top-K produk dengan nilai prediksi tertinggi direkomendasikan	202
5.	Pertimbangan Teoretis:	203
•	<i>Pemilihan Jumlah Fitur Laten:</i>	204
–	Trade-off antara kompleksitas model dan akurasi prediksi	205
–	Dipilih melalui validasi silang untuk optimasi performa	206
•	<i>Penanganan Cold Start:</i>	207
–	Untuk pengguna baru: menggunakan rekomendasi berbasis popularitas	208
–	Untuk produk baru: menggunakan similaritas berbasis konten	209
•	<i>Regularisasi:</i>	210
–	L2 regularization diterapkan untuk mencegah overfitting	211
–	Parameter regularisasi dioptimasi melalui validasi silang	212
2.4.	<i>Algorithm or Model</i>	213
	Pada proyek ini, sistem rekomendasi sepatu dibangun menggunakan model <i>Non-negative Matrix Factorization</i> (NMF), yang merupakan teknik <i>Collaborative Filtering</i> . Berikut adalah langkah-langkah dan detail dari model yang digunakan:	214
1.	Persiapan Data:	215
•	<i>Dataset Interaksi Pengguna</i> dan <i>Dataset Produk</i> digabungkan untuk membentuk matriks pengguna-produk (<i>user-item matrix</i>). Matriks ini berfungsi sebagai dasar untuk pelatihan model.	216
•	Setiap jenis interaksi pengguna (seperti <i>view</i> , <i>wishlist</i> , <i>cart</i> , dan <i>buy</i>) dipetakan ke nilai numerik. Misalnya, <i>view</i> diberi nilai 1, <i>wishlist</i> diberi nilai 2, <i>cart</i> diberi nilai 3, dan <i>buy</i> diberi nilai 4. Pemetaan ini membantu dalam mengukur tingkat ketertarikan pengguna terhadap produk.	217
2.	Pembentukan Matriks:	218
•	Matriks pengguna-produk dibentuk dengan menggunakan nilai interaksi sebagai elemen matriks. Setiap baris mewakili pengguna, dan setiap kolom mewakili produk. Matriks ini menggambarkan hubungan antara pengguna dan produk berdasarkan interaksi yang terjadi.	219
•	Nilai kosong dalam matriks diisi dengan nol untuk menunjukkan tidak adanya interaksi. Hal ini penting untuk memastikan bahwa model dapat memproses data dengan benar tanpa kesalahan.	220
3.	Pelatihan Model NMF:	221
•	Model NMF dilatih menggunakan matriks pengguna-produk. NMF memfaktorkan matriks ini menjadi dua matriks yang lebih kecil: matriks pengguna-fitur (W) dan matriks fitur-produk (H). Proses ini membantu dalam mengidentifikasi pola laten dalam data.	222
•	Matriks W merepresentasikan preferensi laten pengguna, sedangkan matriks H merepresentasikan karakteristik laten produk. Dengan kata lain, W menunjukkan bagaimana setiap pengguna berhubungan dengan fitur-fitur tertentu, dan H menunjukkan bagaimana setiap produk berhubungan dengan fitur-fitur tersebut.	223
•	Parameter model seperti jumlah komponen laten ($n_components$) diatur untuk mengoptimalkan hasil rekomendasi. Pemilihan parameter yang tepat sangat penting untuk meningkatkan akurasi model.	224
4.	Pemberian Rekomendasi:	225

• Untuk pengguna baru, rekomendasi diberikan berdasarkan popularitas produk yang dihitung dari interaksi pengguna lain. Hal ini dilakukan karena tidak ada data interaksi sebelumnya untuk pengguna baru.	247
• Untuk pengguna yang sudah ada, skor preferensi dihitung dengan mengalikan matriks W dan H , dan produk dengan skor tertinggi direkomendasikan. Proses ini memungkinkan sistem untuk memberikan rekomendasi yang dipersonalisasi berdasarkan preferensi pengguna yang telah dipelajari.	248
5. Evaluasi Model:	249
• Model dievaluasi menggunakan metrik seperti <i>Precision@k</i> , <i>Recall@k</i> , dan <i>Mean Average Precision (MAP)@k</i> untuk mengukur akurasi rekomendasi. Evaluasi ini penting untuk memastikan bahwa model memberikan rekomendasi yang relevan.	250
• Precision mengukur proporsi rekomendasi yang relevan dari semua rekomendasi yang diberikan, sedangkan recall mengukur proporsi item relevan yang berhasil direkomendasikan dari semua item relevan yang tersedia. MAP memberikan gambaran keseluruhan tentang akurasi model dalam memberikan rekomendasi yang relevan.	251
Dengan pendekatan ini, sistem rekomendasi dapat memberikan saran produk yang lebih relevan kepada pengguna, meningkatkan pengalaman pengguna dan potensi konversi di platform e-commerce.	252
2.5. <i>Testing (Procedures and Metrics)</i>	253
Pengujian sistem rekomendasi dilakukan untuk memastikan bahwa model memberikan rekomendasi yang akurat dan relevan. Berikut adalah prosedur dan metrik yang digunakan dalam pengujian:	254
1. Prosedur Pengujian:	255
• <i>Split Data</i> : Dataset dibagi menjadi data pelatihan dan data pengujian. Data pelatihan digunakan untuk melatih model, sedangkan data pengujian digunakan untuk mengevaluasi kinerja model.	256
• <i>Pelatihan Model</i> : Model dilatih menggunakan data pelatihan dengan parameter yang telah ditentukan.	257
• <i>Prediksi Rekomendasi</i> : Model menghasilkan rekomendasi untuk pengguna dalam data pengujian.	258
2. Metrik Evaluasi:	259
• <i>Precision@k</i> : Mengukur proporsi rekomendasi yang relevan dari semua rekomendasi yang diberikan hingga posisi ke- k . Precision yang tinggi menunjukkan bahwa model memberikan rekomendasi yang relevan.	260
• <i>Recall@k</i> : Mengukur proporsi item relevan yang berhasil direkomendasikan dari semua item relevan yang tersedia hingga posisi ke- k . Recall yang tinggi menunjukkan bahwa model mampu menangkap sebagian besar item relevan.	261
• <i>Mean Average Precision (MAP)@k</i> : Menghitung rata-rata presisi pada berbagai level cut-off dalam daftar rekomendasi hingga posisi ke- k . MAP memberikan gambaran keseluruhan tentang akurasi model dalam memberikan rekomendasi yang relevan.	262
3. Analisis Hasil:	263
• Hasil pengujian dianalisis untuk mengidentifikasi kekuatan dan kelemahan model. Analisis ini membantu dalam mengoptimalkan model lebih lanjut.	264
• Perbandingan dilakukan antara hasil pengujian dan ekspektasi untuk memastikan bahwa model memenuhi tujuan yang diinginkan.	265
Pengujian ini memastikan bahwa sistem rekomendasi dapat memberikan saran produk yang relevan dan meningkatkan pengalaman pengguna di platform e-commerce.	266

2.6. Evaluation Metrics

1. Precision@K:

- Precision pada peringkat K adalah persentase item yang direkomendasikan dalam K teratas yang relevan bagi pengguna. Precision berfokus pada relevansi dari rekomendasi dalam daftar K teratas, bukan seberapa baik rekomendasi mencakup semua item relevan. Dengan kata lain, metrik ini menjawab pertanyaan: Dari semua item yang direkomendasikan dalam K teratas, berapa banyak yang benar-benar relevan?
- Rumus:

$$\text{Precision@K} = \frac{\text{jumlah item relevan dalam } K \text{ teratas}}{K}$$

- Contoh: Jika kita merekomendasikan 5 item dan 3 di antaranya relevan, maka Precision@5 adalah:

$$\text{Precision@5} = \frac{3}{5} = 0.6$$

2. Recall@K:

- Recall pada peringkat K adalah proporsi item relevan yang berhasil direkomendasikan dalam K teratas. Metrik ini mengukur seberapa baik model menangkap semua item relevan dalam daftar rekomendasi, tanpa memperhitungkan jumlah item yang direkomendasikan. Recall menjawab pertanyaan: Dari semua item yang dianggap relevan oleh pengguna, berapa banyak yang muncul dalam K teratas?
- Rumus:

$$\text{Recall@K} = \frac{\text{jumlah item relevan dalam } K \text{ teratas}}{\text{jumlah total item relevan}}$$

- Contoh: Jika seorang pengguna memiliki 10 item yang relevan tetapi hanya 3 yang muncul dalam K teratas, Recall@K adalah:

$$\text{Recall@10} = \frac{3}{10} = 0.3$$

3. Accuracy@K:

- Dalam konteks ini, Accuracy@K mengukur persentase item yang direkomendasikan dengan benar (hit) di antara semua item relevan, khususnya dalam K teratas. Accuracy mirip dengan Recall tetapi fokus pada perbandingan jumlah item yang direkomendasikan dengan benar relatif terhadap jumlah total item relevan.
- Rumus:

$$\text{Accuracy@K} = \frac{\text{jumlah item relevan yang direkomendasikan dalam } K \text{ teratas}}{\text{jumlah total item relevan}}$$

4. Mean Average Precision (MAP@K):

- MAP@K adalah metrik yang lebih lanjut yang memperhitungkan posisi item relevan dalam daftar rekomendasi. MAP@K mengukur precision di setiap posisi dalam peringkat, lalu menghitung rata-ratanya di semua item relevan. Metrik ini berguna untuk kasus di mana urutan rekomendasi berpengaruh karena item relevan yang muncul lebih awal akan mendapatkan skor lebih tinggi.
- Rumus:

$$\text{MAP@K} = \frac{1}{N} \sum_{i=1}^N \text{Average Precision@K}_i$$

- dengan:

- N adalah jumlah pengguna,
- Average Precision@ K_i adalah rata-rata precision pada K untuk setiap pengguna.

5. Kemiripan Nilai Antara Precision dan MAP, Recall dan Accuracy:

- Berdasarkan dataset yang terdiri dari 500 interaksi pengguna di antara 20 pengguna unik, beberapa pola dapat menjelaskan mengapa precision dan MAP cenderung serupa, dan mengapa nilai recall dan accuracy sering kali mirip.
- *Kemiripan Precision dan MAP*: Baik Precision@ K maupun MAP@ K berfokus pada relevansi item dalam K teratas. Karena MAP memberi bobot lebih tinggi pada item relevan yang muncul di awal daftar rekomendasi, nilai MAP akan cenderung mirip dengan Precision jika sebagian besar item relevan selalu muncul di peringkat atas secara konsisten.
- *Kemiripan Recall dan Accuracy*: Recall@ K dan Accuracy@ K keduanya mengukur seberapa baik daftar rekomendasi mencakup item relevan, meskipun dari perspektif yang sedikit berbeda. Recall adalah persentase item relevan yang muncul dalam rekomendasi, sementara akurasi, seperti yang diimplementasikan di sini, juga menghitung hit di antara item relevan.

3. Problem

Dalam pengembangan website e-commerce sepatu R&R dengan fitur sistem rekomendasi, terdapat beberapa permasalahan utama yang perlu diselesaikan:

3.1. Masalah Bisnis

- **Personalisasi Terbatas**: Platform e-commerce sepatu yang ada saat ini umumnya menampilkan produk yang sama untuk semua pengguna, tanpa mempertimbangkan preferensi individual.
- **Konversi Rendah**: Tanpa sistem rekomendasi yang efektif, pengguna kesulitan menemukan sepatu yang sesuai dengan preferensi mereka, yang mengakibatkan tingkat konversi penjualan yang rendah.
- **Pengalaman Pengguna**: Pengguna harus menghabiskan waktu lebih lama untuk mencari sepatu yang mereka inginkan karena tidak adanya rekomendasi yang dipersonalisasi.

3.2. Tantangan Teknis

- **Data Interaksi Terbatas**:
 - Keterbatasan dalam mengumpulkan data interaksi pengguna yang cukup untuk melatih model rekomendasi.
 - Dataset yang tersedia hanya mencakup 50 produk sepatu dari 5 kategori berbeda.
- **Cold Start Problem**:
 - Kesulitan dalam memberikan rekomendasi yang akurat untuk pengguna baru yang belum memiliki riwayat interaksi.
 - Tantangan dalam merekomendasikan produk baru yang belum memiliki data interaksi.
- **Skalabilitas Sistem**:
 - Kebutuhan untuk memproses dan menganalisis data interaksi pengguna secara real-time.
 - Tantangan dalam memastikan performa sistem tetap optimal saat jumlah pengguna dan produk bertambah.

3.3. Solusi yang Diusulkan

- **Implementasi NMF**: Menggunakan algoritma Non-negative Matrix Factorization untuk sistem rekomendasi yang dapat memberikan saran produk yang dipersonalisasi berdasarkan pola interaksi pengguna.

- **Pendekatan Hybrid:** Menggabungkan rekomendasi berbasis popularitas untuk pengguna baru dengan rekomendasi personal untuk pengguna yang sudah memiliki riwayat interaksi.
- **Optimasi Frontend:** Menggunakan React.js untuk membangun antarmuka yang responsif dan mudah digunakan, memastikan pengalaman pengguna yang optimal.

4. Intelligence System

4.1. System Architecture

Arsitektur sistem e-commerce sepatu ini dirancang untuk mendukung fitur rekomendasi yang efisien dan responsif. Sistem ini terdiri dari beberapa komponen utama yang bekerja secara sinergis untuk memberikan pengalaman pengguna yang optimal.

1. Frontend:

- *React.js* digunakan untuk membangun antarmuka pengguna yang dinamis dan interaktif. *React.js* dipilih karena kemampuannya dalam mengelola komponen UI yang kompleks dan memperbarui tampilan secara efisien.
- Komponen frontend bertanggung jawab untuk menampilkan produk, menangani interaksi pengguna seperti pencarian dan filter, serta menampilkan rekomendasi produk secara real-time.
- Antarmuka pengguna dirancang agar responsif dan mudah digunakan, memastikan bahwa pengguna dapat dengan mudah menemukan dan membeli produk yang mereka inginkan.

2. Backend:

- *Flask* digunakan sebagai framework web untuk mengembangkan API yang menghubungkan frontend dengan database dan model rekomendasi. *Flask* dipilih karena kesederhanaan dan fleksibilitasnya dalam menangani permintaan HTTP.
- Backend bertanggung jawab untuk memproses permintaan dari frontend, seperti permintaan data produk dan interaksi pengguna, serta mengelola logika bisnis untuk rekomendasi.
- *SQLite* digunakan sebagai database untuk menyimpan data produk dan interaksi pengguna. *SQLite* dipilih karena kemudahan penggunaan, integrasi yang mulus dengan *Flask*, dan kemampuan untuk menangani data dalam skala kecil hingga menengah.
- Database dirancang untuk menyimpan informasi produk, kategori, dan riwayat interaksi pengguna, yang semuanya penting untuk menghasilkan rekomendasi yang akurat.

3. Model Rekomendasi:

- Model rekomendasi dibangun menggunakan *Non-negative Matrix Factorization (NMF)*, yang merupakan teknik collaborative filtering. *NMF* digunakan untuk mengidentifikasi pola laten dalam data interaksi pengguna.
- Model ini diintegrasikan ke dalam backend untuk memproses data secara efisien dan memberikan rekomendasi yang dipersonalisasi kepada pengguna.
- Proses rekomendasi melibatkan analisis data interaksi pengguna untuk mengidentifikasi preferensi dan memberikan saran produk yang relevan, meningkatkan pengalaman belanja pengguna.

Arsitektur ini dirancang untuk memastikan bahwa sistem dapat menangani permintaan pengguna dengan cepat dan memberikan pengalaman belanja yang dipersonalisasi dan memuaskan. Dengan memanfaatkan teknologi modern seperti *React.js* dan *Flask*, sistem ini mampu memberikan layanan yang responsif dan efisien.

4.2. System Workflow	430
Alur kerja sistem e-commerce sepatu R&R dengan fitur rekomendasi terdiri dari beberapa tahapan utama yang saling terhubung:	431
	432
4.2.1. Alur Interaksi Pengguna	433
1. Registrasi dan Login:	434
• Pengguna baru melakukan registrasi dengan memasukkan data diri	435
• Pengguna yang sudah terdaftar dapat langsung login ke sistem	436
• Sistem memverifikasi kredensial pengguna	437
2. Browsing Produk:	438
• Pengguna dapat melihat katalog produk sepatu	439
• Sistem mencatat setiap interaksi view produk	440
• Pengguna dapat melakukan filter berdasarkan kategori	441
3. Interaksi dengan Produk:	442
• Menambahkan produk ke wishlist	443
• Memasukkan produk ke keranjang belanja	444
• Melakukan pembelian produk	445
• Setiap interaksi dicatat dalam database	446
4.2.2. Alur Sistem Rekomendasi	447
1. Pengumpulan Data:	448
• Sistem mengumpulkan data interaksi pengguna secara real-time	449
• Data interaksi meliputi view, wishlist, cart, dan purchase	450
• Data disimpan dalam format terstruktur di database	451
2. Pemrosesan Data:	452
• Data interaksi dikonversi menjadi matriks user-item	453
• Sistem menerapkan pembobotan berdasarkan jenis interaksi	454
• Model NMF memproses matriks untuk menghasilkan rekomendasi	455
3. Generasi Rekomendasi:	456
• Untuk pengguna baru: rekomendasi berbasis popularitas	457
• Untuk pengguna existing: rekomendasi personal berbasis NMF	458
• Hasil rekomendasi ditampilkan di antarmuka pengguna	459
4.2.3. Alur Backend Processing	460
1. Manajemen Data:	461
• Penyimpanan data produk dan interaksi di SQLite	462
• Pembaruan data secara real-time	463
• Backup dan maintenance database	464
2. API Endpoints:	465
• Endpoint untuk manajemen pengguna	466
• Endpoint untuk operasi CRUD produk	467
• Endpoint untuk sistem rekomendasi	468
3. Response Handling:	469
• Pemrosesan permintaan dari frontend	470
• Pengiriman response dalam format JSON	471
• Penanganan error dan exception	472

4.2.4. Class Diagram

473

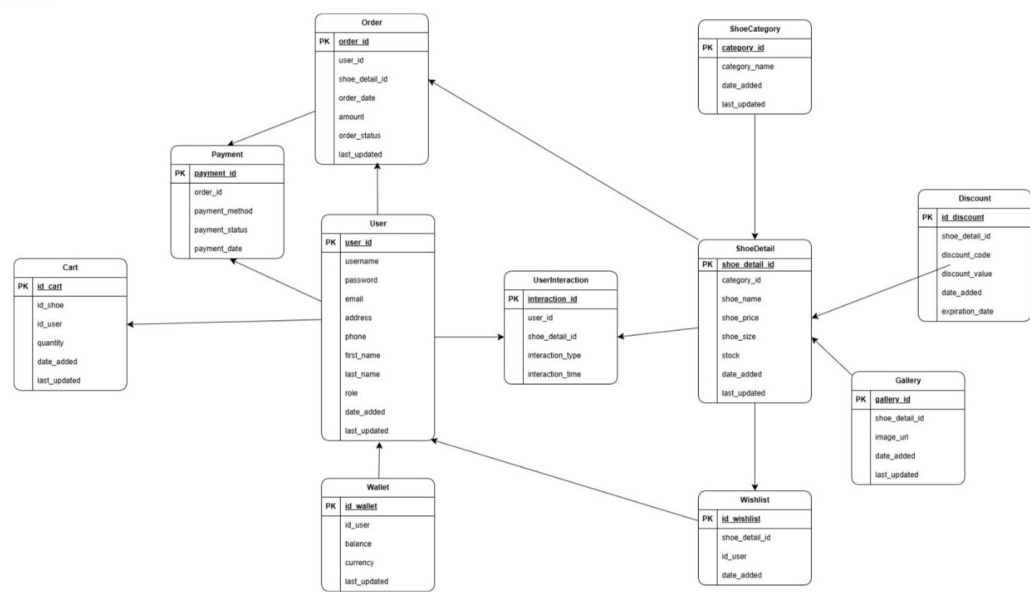


Figure 1. Class Diagram

- **User Management:**
 - Tabel User sebagai pusat data pengguna dengan atribut lengkap seperti username, password, email, dll.
 - Terhubung dengan Wallet untuk manajemen saldo pengguna
 - Memiliki relasi dengan Cart, Order, dan Wishlist untuk aktivitas pembelian
- **Product Management:**
 - Tabel ShoeDetail sebagai pusat informasi produk
 - Terhubung dengan ShoeCategory untuk klasifikasi produk
 - Memiliki Gallery untuk manajemen gambar produk
 - Terintegrasi dengan Discount untuk pengelolaan promosi
- **Transaction Management:**
 - Tabel Order untuk pencatatan pembelian
 - Terhubung dengan Payment untuk proses pembayaran
 - Terintegrasi dengan Cart untuk proses checkout
- **Recommendation System:**
 - Tabel UserInteraction untuk mencatat aktivitas pengguna
 - Menjadi dasar untuk sistem rekomendasi berbasis NMF

4.2.5. Use Case Diagram

491

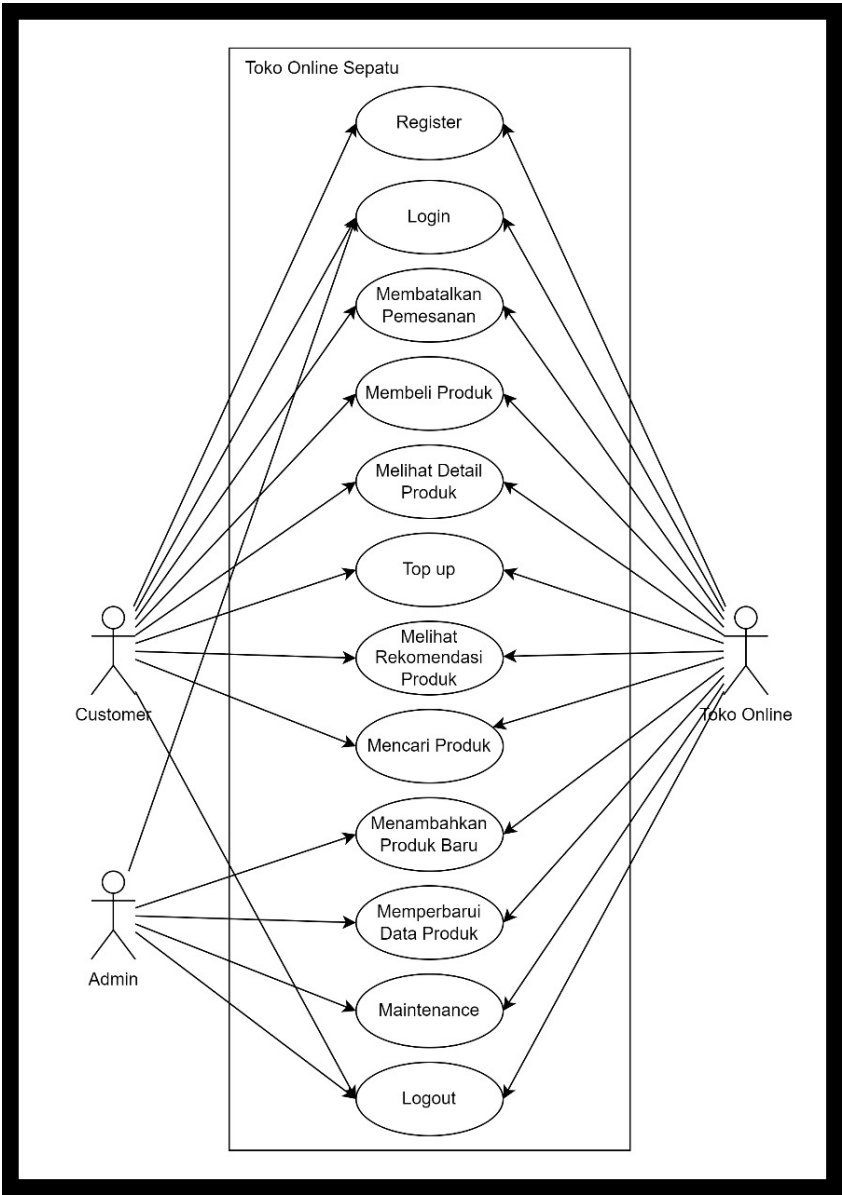


Figure 2. UML Diagram

- **Customer Activities:**
 - Manajemen akun (register, login, logout)
 - Aktivitas belanja (melihat produk, membeli, membatalkan pesanan)
 - Fitur wallet (top up)
 - Akses rekomendasi dan pencarian produk
- **Admin Activities:**
 - Manajemen produk (menambah, memperbarui)
 - Maintenance sistem
 - Login dan logout admin

492
493
494
495
496
497
498
499
500

4.2.6. Activity Diagrams

501

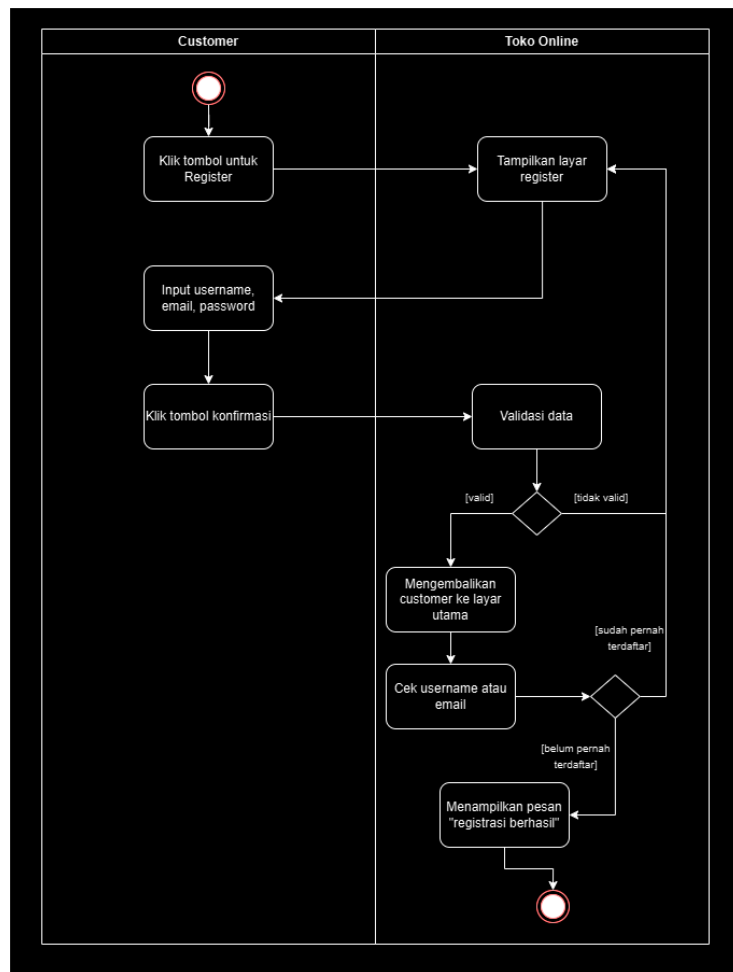


Figure 3. Activity Diagram Register

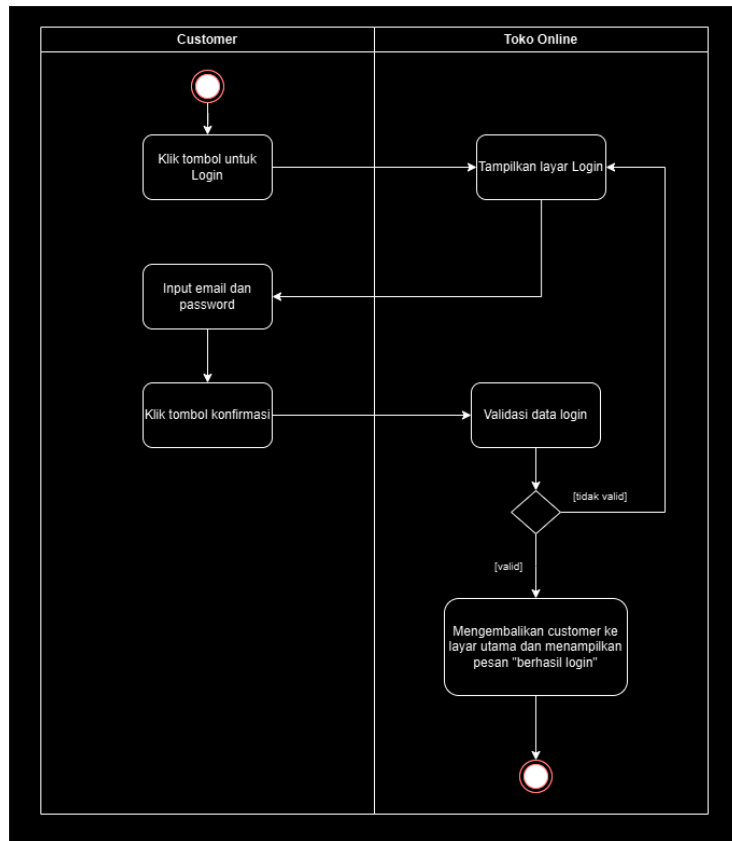


Figure 4. Activity Diagram Login

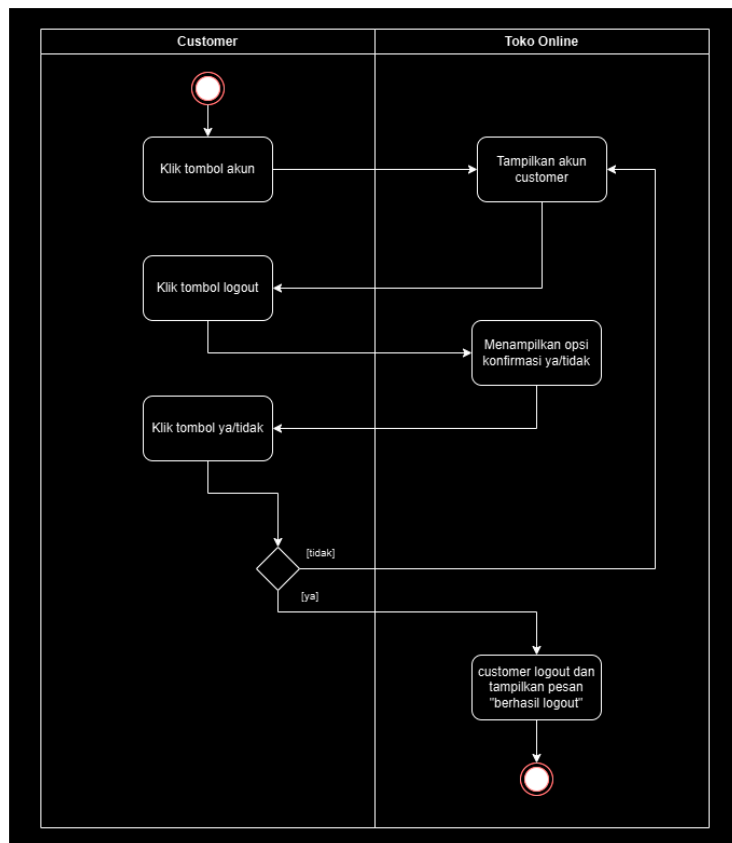


Figure 5. Activity Diagram Logout

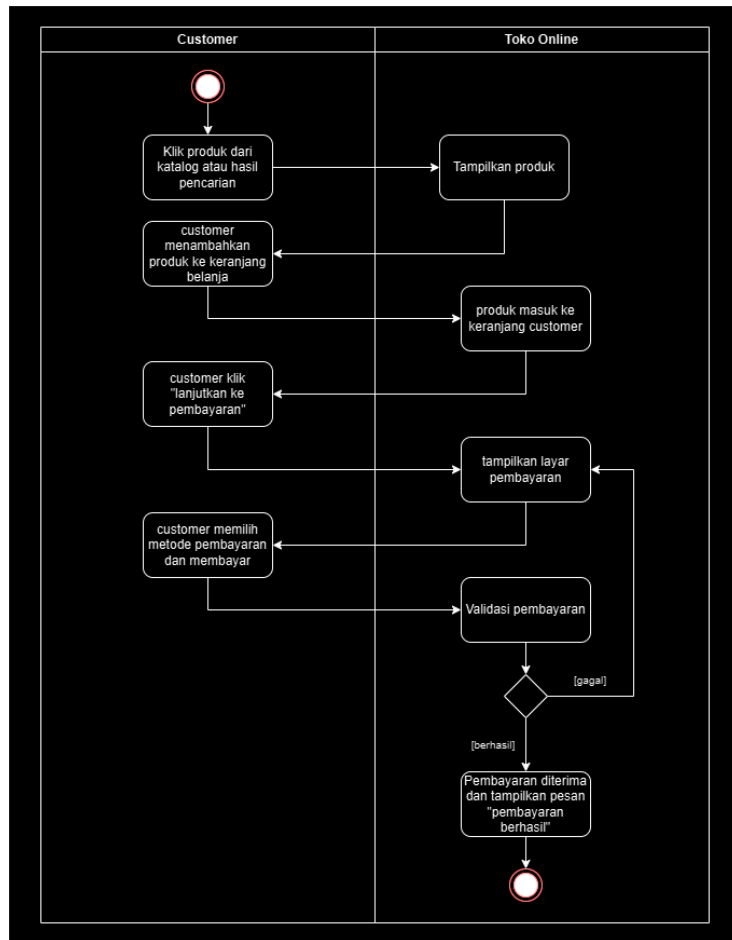


Figure 6. Activity Diagram Membeli Sepatu

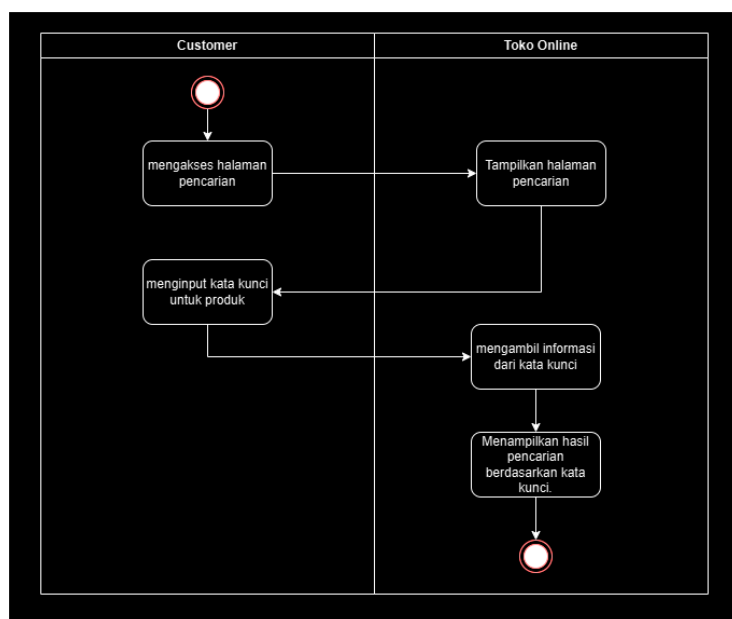


Figure 7. Activity Diagram Search Sepatu

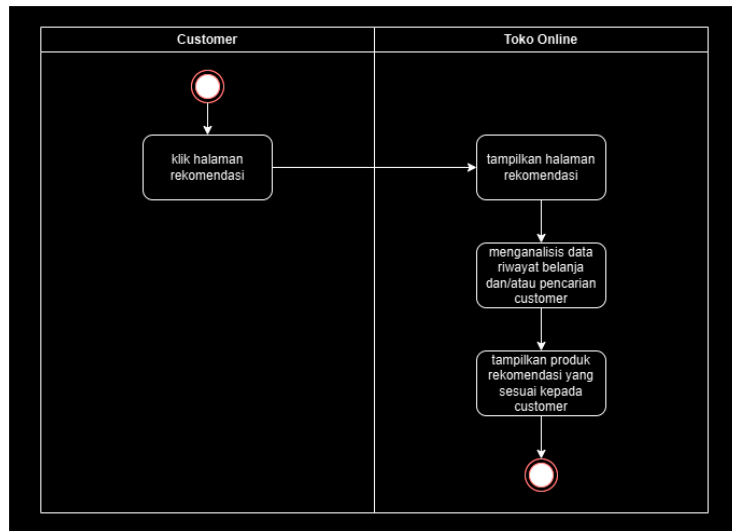


Figure 8. Activity Diagram Rekomendasi Sepatu

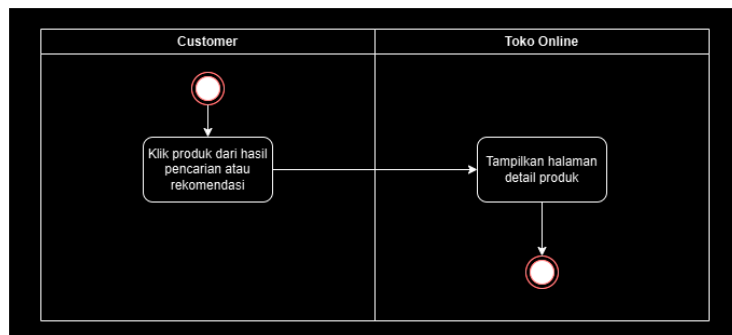


Figure 9. Activity Diagram Melihat Detail Sepatu

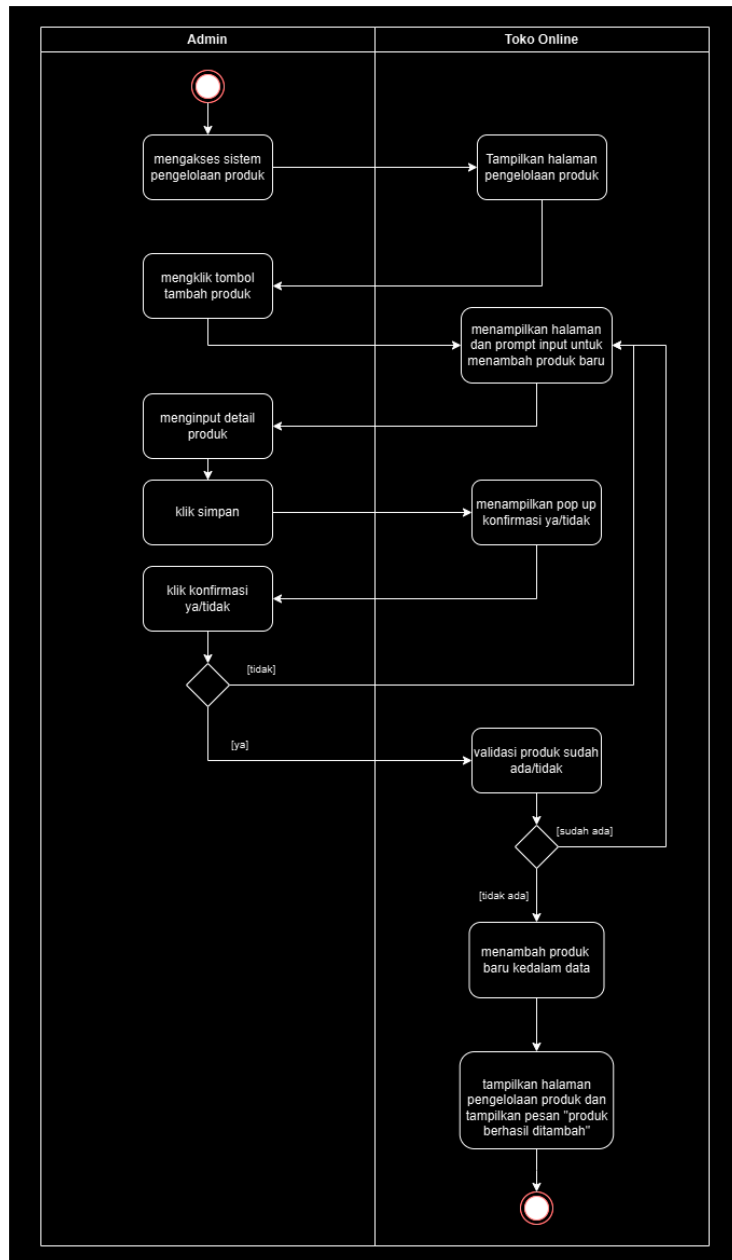


Figure 10. Activity Diagram Menambah Sepatu

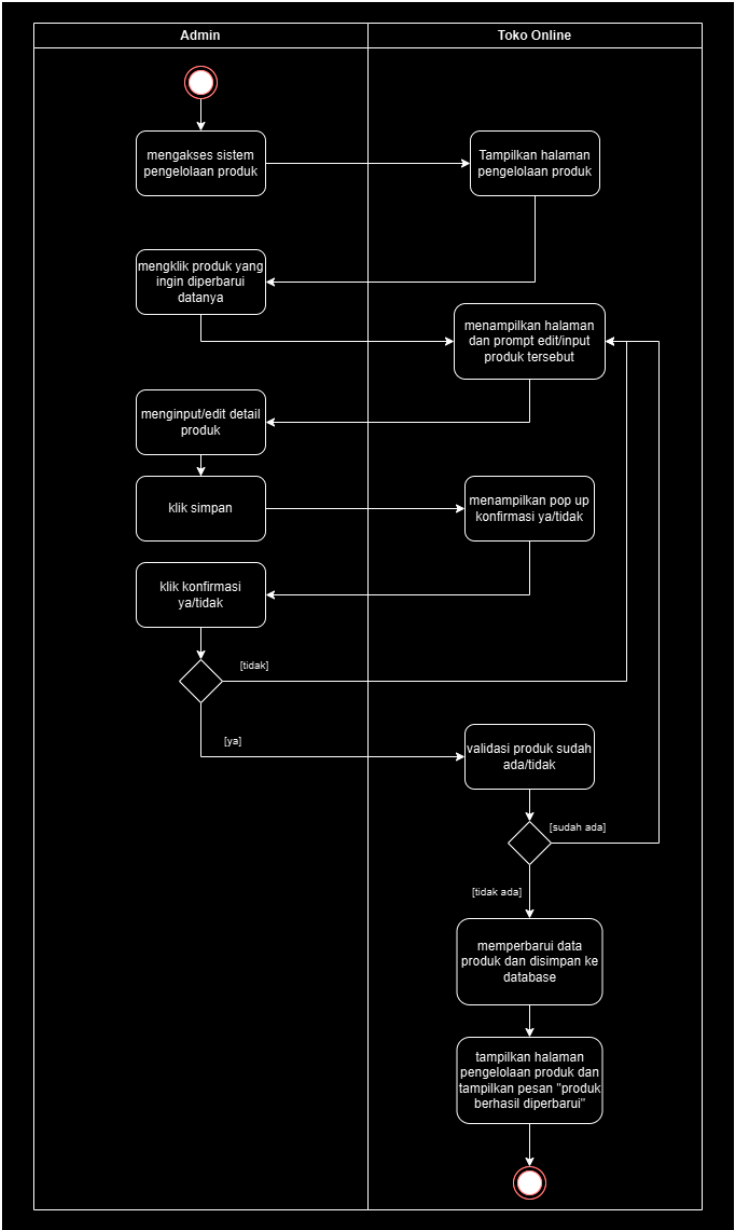


Figure 11. Activity Diagram Update Sepatu


5. Project Documentation	502
5.1. Implementation	503
• Analisis Kebutuhan Detail:	504
– Menganalisis pola belanja online pengguna untuk mengidentifikasi area yang dapat dioptimalkan	505
– Menentukan fitur-fitur utama yang diperlukan dalam sistem rekomendasi	506
– Mengidentifikasi teknologi yang sesuai untuk pengembangan platform	507
• Pengembangan & Pengujian Sistem:	508
– Membangun frontend menggunakan React.js untuk antarmuka yang responsif	509
– Mengembangkan backend dengan Flask dan mengintegrasikan sistem rekomendasi NMF	510
– Melakukan pengujian untuk memastikan akurasi rekomendasi dan kinerja sistem	511
• Integrasi Sistem E-commerce:	512
– Mengintegrasikan sistem rekomendasi dengan katalog produk	513
	514
	515

- Memastikan sistem pembayaran dan keranjang belanja berfungsi dengan baik516
- Mengoptimalkan performa sistem secara keseluruhan517

5.2. Results and Discussion518

5.2.1. Hasil Evaluasi Model519

- Gambar Evaluasi Metrik:520



- 521
- **Evaluation Metrics untuk User ID 12:**522
 - * *Precision@10*: 1.0523
 - * *Recall@10*: 0.53524
 - * *MAP@10*: 1.0525
 - * *Accuracy@10*: 0.53526
- **Evaluation Metrics untuk User ID 7:**527
 - * *Precision@10*: 1.0528
 - * *Recall@10*: 0.5529
 - * *MAP@10*: 1.0530
 - * *Accuracy@10*: 0.5531
- **Evaluation Metrics untuk User ID 5:**532
 - * *Precision@10*: 1.0533
 - * *Recall@10*: 0.56534
 - * *MAP@10*: 1.0535
 - * *Accuracy@10*: 0.56536
- **Evaluation Metrics untuk User ID 14:**537
 - * *Precision@10*: 1.0538
 - * *Recall@10*: 0.4539
 - * *MAP@10*: 1.0540
 - * *Accuracy@10*: 0.4541
- **Evaluation Metrics untuk User ID 19:**542
 - * *Precision@10*: 0.8543
 - * *Recall@10*: 0.4544
 - * *MAP@10*: 1.0545
 - * *Accuracy@10*: 0.4546
- **Evaluation Metrics untuk User ID 11:**547
 - * *Precision@10*: 1.0548
 - * *Recall@10*: 0.56549
 - * *MAP@10*: 1.0550
 - * *Accuracy@10*: 0.56551
- **Simpulan:**552
 - Setiap modul pengguna menunjukkan variasi dalam metrik evaluasi, yang mencerminkan perbedaan dalam pola interaksi dan preferensi pengguna.553554

- Pengguna dengan riwayat interaksi yang lebih kaya cenderung memiliki nilai precision dan recall yang lebih tinggi, menunjukkan bahwa model dapat memberikan rekomendasi yang lebih akurat.
- Variasi dalam MAP dan accuracy menunjukkan bahwa meskipun model memberikan rekomendasi yang relevan, ada ruang untuk peningkatan dalam menangkap semua item relevan.

5.2.2. Discussion

Website e-commerce R&R dengan sistem rekomendasi telah berhasil diimplementasikan dan menunjukkan hasil yang menjanjikan. Sistem ini dibangun menggunakan dataset yang terdiri dari 50 produk sepatu yang terbagi dalam 5 kategori utama: formal, sport, heels, boots, dan casual. Setiap kategori memiliki 10 jenis sepatu yang berbeda, memberikan variasi yang cukup untuk pengujian sistem rekomendasi.

Implementasi algoritma Non-negative Matrix Factorization (NMF) terbukti efektif dalam mengidentifikasi pola laten dari data interaksi pengguna. Model ini berhasil menganalisis berbagai jenis interaksi seperti view, wishlist, cart, dan purchase untuk menghasilkan rekomendasi yang dipersonalisasi. Untuk pengguna yang telah memiliki riwayat interaksi, sistem mampu memberikan rekomendasi yang lebih akurat dan relevan dengan preferensi mereka. Sementara itu, untuk mengatasi cold start problem pada pengguna baru, sistem menerapkan pendekatan hybrid dengan menggabungkan rekomendasi berbasis popularitas.

Dari segi antarmuka pengguna, website berhasil mengintegrasikan sistem rekomendasi dengan tampilan yang responsif menggunakan React.js. Halaman utama dirancang dengan layout yang intuitif, menampilkan berbagai kategori produk dan rekomendasi yang dipersonalisasi. Proses autentikasi pengguna dibuat sederhana namun tetap memperhatikan aspek keamanan. Halaman katalog dan detail produk menyajikan informasi yang komprehensif, memudahkan pengguna dalam mengambil keputusan pembelian.

Meskipun sistem menunjukkan performa yang baik, beberapa tantangan masih perlu diatasi. Keterbatasan dataset dengan hanya 50 produk mempengaruhi keragaman rekomendasi yang dapat diberikan. Cold start problem, terutama untuk pengguna baru, masih menjadi tantangan meskipun telah dimitigasi dengan pendekatan hybrid. Selain itu, variasi dalam metrik evaluasi seperti MAP dan accuracy menunjukkan bahwa masih ada ruang untuk peningkatan dalam menangkap semua item yang relevan.

Secara keseluruhan, implementasi sistem rekomendasi pada platform e-commerce R&R telah berhasil meningkatkan pengalaman berbelanja pengguna dengan memberikan rekomendasi yang relevan dan dipersonalisasi. Untuk pengembangan ke depan, peningkatan jumlah dataset dan penyempurnaan algoritma akan menjadi fokus utama untuk meningkatkan akurasi dan relevansi rekomendasi lebih lanjut.

5.3. Conclusion

Website e-commerce sepatu R&R dengan sistem rekomendasi berbasis machine learning telah berhasil dikembangkan dan diimplementasikan dengan hasil yang menjanjikan. Dengan memanfaatkan algoritma Non-negative Matrix Factorization (NMF), platform ini mampu menganalisis pola interaksi pengguna seperti view, wishlist, cart, dan pembelian untuk memberikan rekomendasi produk yang dipersonalisasi. Sistem ini tidak hanya memudahkan pengguna dalam menemukan sepatu yang sesuai dengan preferensi mereka, tetapi juga meningkatkan efisiensi dalam proses pencarian produk.

Melalui integrasi teknologi modern seperti React.js untuk frontend dan Flask untuk backend, platform ini menyajikan antarmuka yang responsif dan pengalaman pengguna yang optimal. Hasil evaluasi menunjukkan performa yang baik dengan nilai Precision@10 rata-rata mencapai 0.96 dan MAP@10 yang konsisten mencapai 1.0, mengindikasikan akurasi yang tinggi dalam memberikan rekomendasi yang relevan. Meskipun terdapat

variasi dalam nilai Recall@10 yang berkisar antara 0.4 hingga 0.56, hal ini menunjukkan bahwa model masih memiliki ruang untuk peningkatan dalam menangkap semua item yang relevan.

Platform ini berhasil mengatasi tantangan umum dalam sistem rekomendasi e-commerce, seperti cold start problem, dengan mengadopsi pendekatan hybrid yang menggabungkan rekomendasi berbasis popularitas untuk pengguna baru. Meskipun demikian, keterbatasan dataset yang hanya mencakup 50 produk sepatu mempengaruhi keragaman rekomendasi yang dapat diberikan. Untuk pengembangan ke depan, peningkatan jumlah dataset dan penyempurnaan algoritma akan menjadi fokus utama untuk meningkatkan akurasi dan relevansi rekomendasi.

Secara keseluruhan, implementasi sistem rekomendasi pada platform e-commerce R&R telah berhasil menciptakan pengalaman berbelanja yang lebih personal dan efisien. Dengan mengotomatisasi proses rekomendasi produk berdasarkan preferensi pengguna, platform ini tidak hanya meningkatkan kepuasan pelanggan tetapi juga berpotensi meningkatkan konversi penjualan. Keberhasilan ini menunjukkan bahwa integrasi teknologi machine learning dalam e-commerce dapat memberikan nilai tambah yang signifikan dalam meningkatkan pengalaman berbelanja online.

6. Appendices (if applicable)

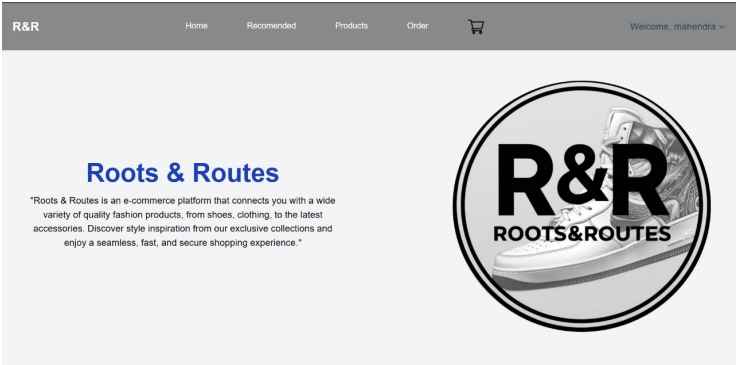


Figure 12. Homopage

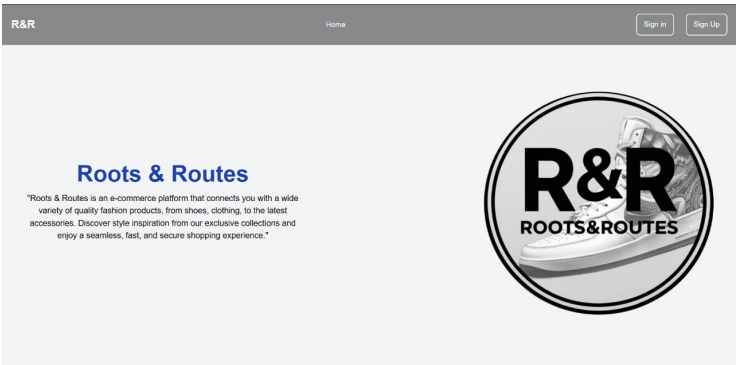


Figure 13. Homepage Tanpa Login

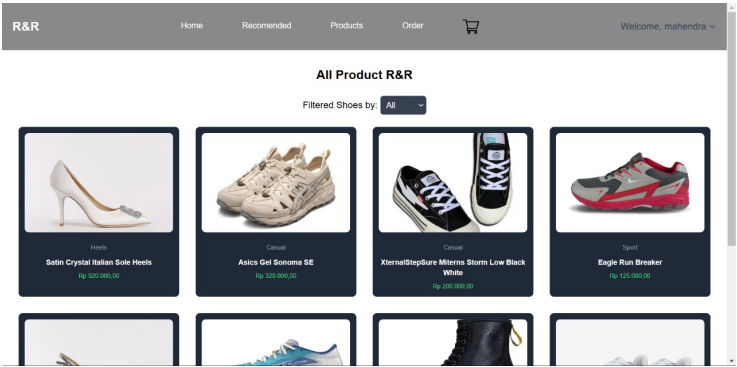


Figure 14. Product Page

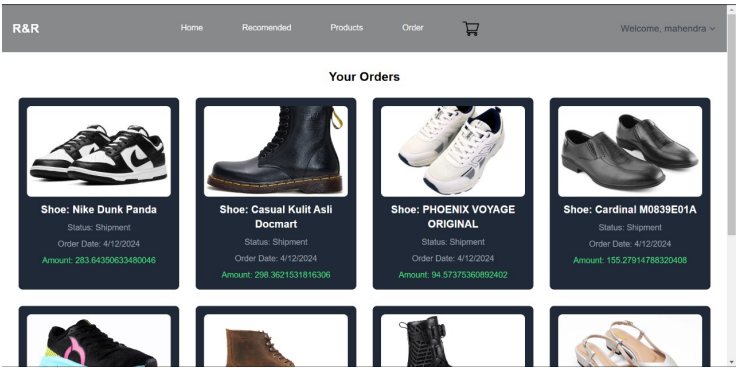


Figure 15. Order Page

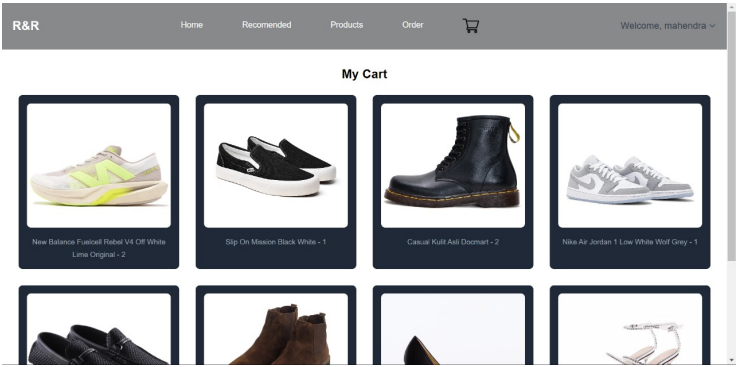


Figure 16. Cart Page

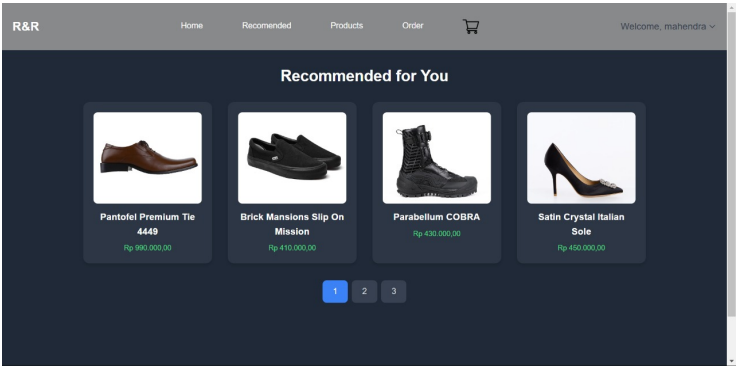


Figure 17. Recommended Page

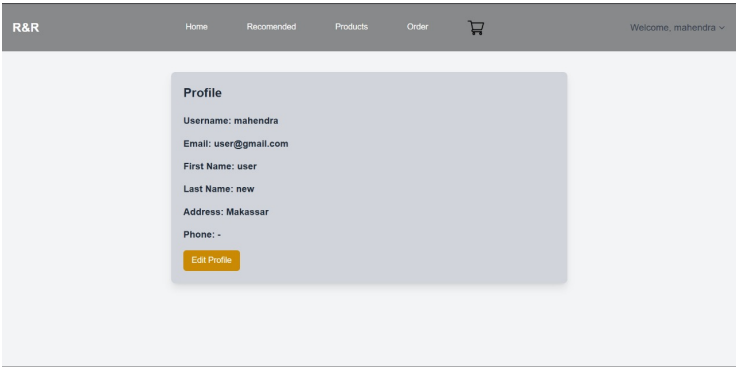


Figure 18. Profile Page

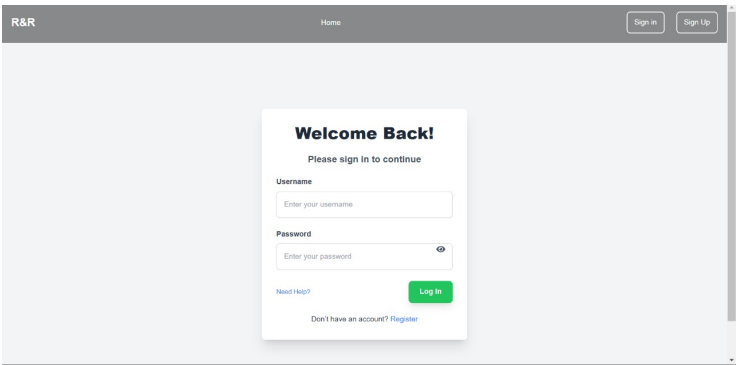


Figure 19. Signin Page

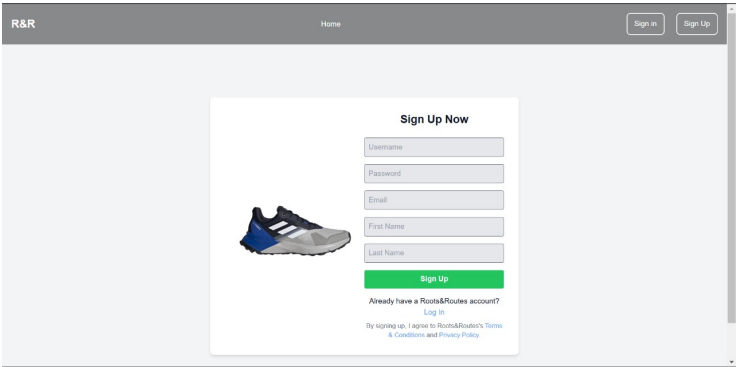


Figure 20. Signup Page

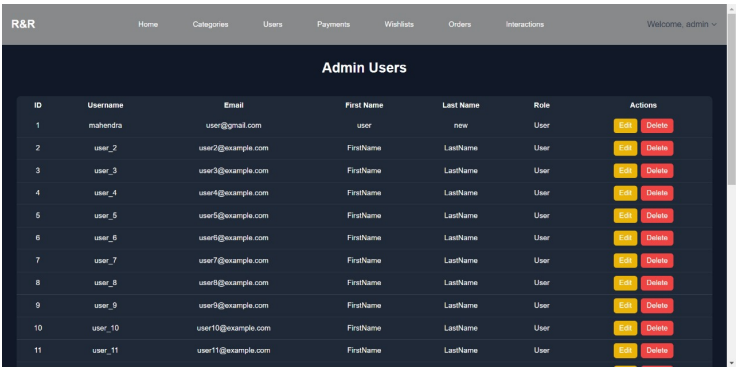
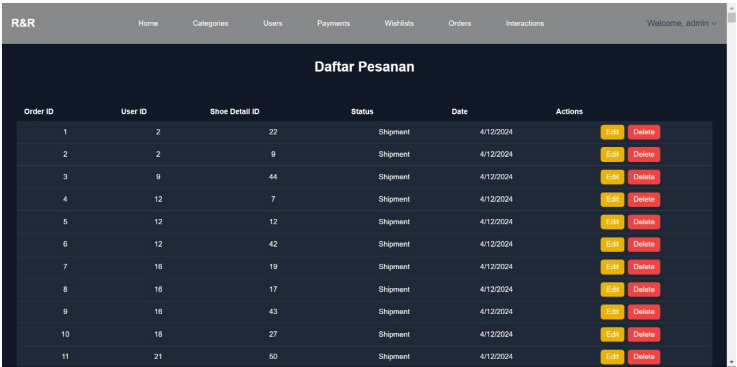


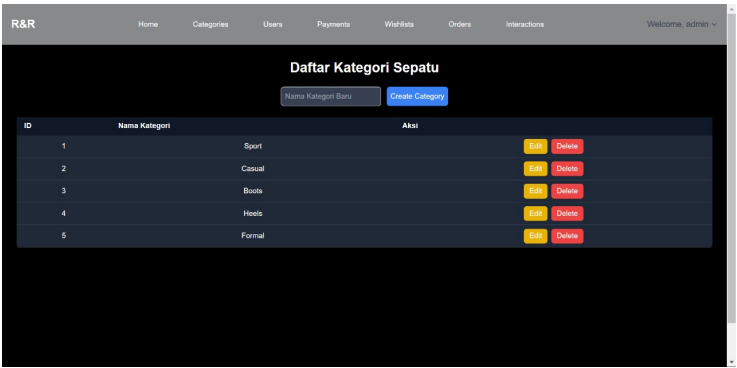
Figure 21. User Admin Page



The screenshot shows the 'Daftar Pesanan' (Order List) page in the R&R admin interface. The page has a dark theme and a sidebar with navigation links: Home, Categories, Users, Payments, Wishlists, Orders, and Interactions. The main content area displays a table of orders with columns for Order ID, User ID, Shoe Detail ID, Status, Date, and Actions. The table contains 11 rows of data, all with a status of 'Shipment' and a date of '4/12/2024'. Each row has 'Edit' and 'Delete' buttons in the Actions column.

Order ID	User ID	Shoe Detail ID	Status	Date	Actions
1	2	22	Shipment	4/12/2024	Edit Delete
2	2	9	Shipment	4/12/2024	Edit Delete
3	9	44	Shipment	4/12/2024	Edit Delete
4	12	7	Shipment	4/12/2024	Edit Delete
5	12	12	Shipment	4/12/2024	Edit Delete
6	12	42	Shipment	4/12/2024	Edit Delete
7	16	19	Shipment	4/12/2024	Edit Delete
8	16	17	Shipment	4/12/2024	Edit Delete
9	16	43	Shipment	4/12/2024	Edit Delete
10	18	27	Shipment	4/12/2024	Edit Delete
11	21	50	Shipment	4/12/2024	Edit Delete

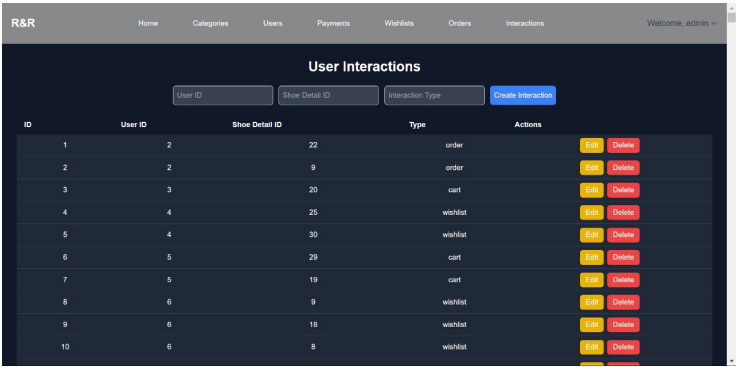
Figure 22. Order Admin Page



The screenshot shows the 'Daftar Kategori Sepatu' (Shoe Category List) page in the R&R admin interface. The page has a dark theme and a sidebar with navigation links: Home, Categories, Users, Payments, Wishlists, Orders, and Interactions. The main content area displays a table of shoe categories with columns for ID, Name Kategori, and Aksi. The table contains 5 rows of data. Above the table, there are input fields for 'Name Kategori Baru' and a 'Create Category' button. Each row has 'Edit' and 'Delete' buttons in the Aksi column.

ID	Name Kategori	Aksi
1	Sport	Edit Delete
2	Casual	Edit Delete
3	Boots	Edit Delete
4	Heels	Edit Delete
5	Formal	Edit Delete

Figure 23. Categories Admin Page



The screenshot shows the 'User Interactions' page in the R&R admin interface. The page has a dark theme and a sidebar with navigation links: Home, Categories, Users, Payments, Wishlists, Orders, and Interactions. The main content area displays a table of user interactions with columns for ID, User ID, Shoe Detail ID, Type, and Actions. The table contains 10 rows of data. Above the table, there are input fields for 'User ID', 'Shoe Detail ID', and 'Interaction Type', along with a 'Create Interaction' button. Each row has 'Edit' and 'Delete' buttons in the Actions column.

ID	User ID	Shoe Detail ID	Type	Actions
1	2	22	order	Edit Delete
2	2	9	order	Edit Delete
3	3	20	cart	Edit Delete
4	4	25	wishlist	Edit Delete
5	4	30	wishlist	Edit Delete
6	5	29	cart	Edit Delete
7	5	19	cart	Edit Delete
8	6	9	wishlist	Edit Delete
9	6	16	wishlist	Edit Delete
10	6	8	wishlist	Edit Delete

Figure 24. User Interaction Admin Page